

Analiza cross-domain klasyfikacji sentymentu tekstu dla modeli SVM + TF-IDF, LSTM, MiniLM i DistilBERT

Selega Kamil (288780),
Sielska Małgorzata (266560),
Szczepaniak Katarzyna (261895),
Szeląg Magdalena (266857)

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji (W4N)
Kierunek: Zaufane Systemy Sztucznej Inteligencji (TAI)
Kurs: Przetwarzanie Języka Naturalnego

Zarys tematu

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (z ang. *out-of-domain text classification*, OOD). Głównym celem ewaluacji jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z zupełnie innego źródła. Spadek skuteczności w docelowym środowisku jest powszechnym problemem, dlatego celem pracy jest mierzalna, statystyczna weryfikacja utraty zdolności generalizacyjnych (przy użyciu metryk *accuracy* i *F1*) na zadaniu analizy sentymentu.

Studium literaturowe

Problem generalizacji modeli na dane spoza domeny treningowej od dawna stanowi jedno z większych wyzwań przetwarzania języka naturalnego. Ramy teoretyczne tego zjawiska opisują m.in. Yang i in. [19] oraz Lang i in. [8]. Zwracają oni uwagę, że pomimo świetnych wyników współczesnych sieci neuronowych w obrębie znanych danych docelowych (in-domain), skuteczność klasyfikacji drastycznie spada przy zetknięciu z innym kontekstem wypowiedzi. Początki prób przeciwdziałania temu zjawisku sięgają klasycznej adaptacji domenowej nakierowanej jeszcze na stare klasyfikatory statystyczne, co analizowali chociażby Daumé III i Marcu [5]. Wraz z narastającym skomplikowaniem sieci, uwaga analityków przesunęła się m.in. na rozpoznawanie nowych intencji z ujęciem metod nienadzorowanych (bez etykiet nowej domeny) [6] czy ugruntowanie pewności i bezpieczeństwa najnowszych zautomatyzowanych chatbotów konwersacyjnych [22].

Trudności z generalizacją na dane spoza domeny wymuszają nowe metody analiz w zróżnicowanych gałęziach NLP: obniżają jakość tłumaczenia maszynowego [4], ograniczają ekstrakcję encji (ang. *named entity recognition*) podczas

analiz tekstów medycznych [1], a nawet generują szum decyzyjny przy segmentowaniu izolowanych tekstów języków azjatyckich przeplatanych wtrąceniami europejskimi [10]. Zjawisko wykracza daleko poza ramy NLP i dotyczy też kategoryzacji obrazów wizyjnych, chociażby klasyfikacji środowiska na podstawie rzutów satelitarnych [7].

Obok głębokich ujęć rekurencyjnych (LSTM) standardami w zadaniach kategoryzacji zdań i wyszukiwania tekstu stały się od niedawna reprezentacje oparte natywnie na mechanizmie uwagi (Transformer, m.in. popularny BERT). Szerokiej weryfikacji takich architektur podjęli się badawczo i polecają takie metody m.in. Sharma [16] oraz Oday i in. [13]. Istotną luką pozostaje jednak ograniczanie rozmiaru tych modeli. Stąd naukowcy zwrócili się ku mniejszym, ale zoptymalizowanym przez transfer learning wersjom tych samych modeli, na czele z DistilBERT-em. Barbon i Akabane [17] potwierdzili badawczo wysoką, często zaskakującą skuteczność lekkiego DistilBERT-a w niwelowaniu różnic między domenami w analizach wielojęzycznych w porównaniu do starszych architektur klasyfikacyjnych; podobne wnioski przedstawili Muffo i Bertino, testując zjawisko na dużych zasobach tekstowych dla języka włoskiego [12]. Co najważniejsze z perspektywy badanego w tym projekcie problemu, Yuan [21] potwierdził na zbiorach IMDb skuteczność lekkiej wersji DistilBERT, wykazując przewagę klasyfikacji opartej na Transformerze nad klasycznymi sieciami głębokimi (CNN i LSTM). Jednocześnie warto wspomnieć, że badając tak złożone architektury należy posługiwać się decyzjami popartymi jasnymi wyjaśnieniami (ang. *explanations*), co dla modeli OOD szerzej wykazali Chrysostomou i Aletras [2].

Plan eksperymentu

Opierając się na powyższym przeglądzie, zdecydowano się przetestować algorytmy na zadaniu klasyfikacji sentymentu stosując ewaluację międzydomenową (ang. *cross-domain*). Zamiast ustalać wyłącznie jedną domenę bazową, każda z zademonstrowanych architektur będzie trenowana niezależnie dla każdego poszczególnego zbioru danych. Po wytrenowaniu modelu na danym zbiorze (źródłowym), zostanie on przetestowany na nim samym (ewaluacja *in-domain*, dalej IND) oraz na każdym z pozostałych (ewaluacja *out-of-domain*, dalej OOD). Badanie rotacyjnie obejmie poniższe zbiory:

- **IMDb Dataset:** 50 000 recenzji filmowych, zbalansowane (25 000 / 25 000); etykiety z pola *sentiment*. Często używane jako bazowy punkt odniesienia jakości modeli głębokich w analizie sentymentu [21,11].
- **Rotten Tomatoes Dataset:** spośród oryginalnego zbioru wylosowano 50 000 zrównoważonych recenzji krytyków filmowych (25 000 / 25 000); etykiety z pola *review_type*: *fresh*→1, *rotten*→0 [9].
- **Amazon Reviews Dataset:** 21 055 recenzji produktów, niezbalansowane (6 705 pozytywnych / 14 350 negatywnych); etykiety z pola *Rating* (ocena ≥ 3 oznacza recenzję pozytywną) [3].

- **Yelp Reviews**: 10 000 recenzji lokalnych usług, niebalansowane (8 324 pozytywne / 1 676 negatywnych); etykiety z pola *stars* (ocena ≥ 3 oznacza recenzję pozytywną) [20].

Wszystkie teksty przetworzono wspólnym potokiem czyszczącym: konwersja do małych liter, usunięcie znaczników HTML, adresów URL, znaków niealfabetycznych oraz normalizacja białych znaków. Niebalansowanie zbiorów Amazon i Yelp zostało świadomie zachowane, co stanowi materiał do trzeciego pytania badawczego. Dzięki zbudowaniu pełnej macierzy testowej (każdy model trenowany kolejno na jednej z czterech domen i testowany na wszystkich czterech) badanie pozwoli zmierzyć, w jakim stopniu zmiana domeny wpływa na parametry dokładności modeli, których tło teoretyczne opisują Yang i Lang [19,8]. W ramach protokołów testowych przyjmuje się rygorystyczny podział każdego ze środowisk danych. Aby zapewnić wiarygodność doboru hiperparametrów i uniknąć przetrenowania na zbiorze źródłowym, na etapie treningu zastosowana zostanie *k*-krotna walidacja krzyżowa (ang. *k-fold cross-validation*). Finalna ewaluacja każdego modelu przeprowadzona zostanie natomiast na wydzielonych zbiorach testowych, zarówno IND, jak i OOD, co umożliwi miarodajne i statystycznie poprawne porównania cross-domain.

Do weryfikacji celów postawiono na zróżnicowany stack algorytmiczny, aby porównać skuteczność pomiędzy starymi standardami klasyfikacyjnymi i innowacyjnym użyciem uwag i transformatorów [5,17]. Posłużą temu cztery stopnie trudności badanej architektury:

1. **SVM + wektoryzacja TF-IDF**, reprezentująca optymalny wczesny model z nurtu klasyfikatorów statystycznych, tworząca próg bazowego startu eksperymentu.
2. **LSTM**, stanowiący stabilniejszy, bazowy standard przetwarzania, nierzadko słabszy od modeli Transformerowych na danych spoza domeny, co Yuan [21] wskazuje jako punkt odniesienia do pomiaru siły tych różnic.
3. **MiniLM (sentence-transformers)**, czyli lekki transformator zdaniowy używany w trybie zamrożonym jako ekstraktor cech, stanowiący kompromis pomiędzy klasycznym LSTM a pełnym dostrajaniem modeli językowych [18,14]. Pierwotnie planowany w jego miejscu pełny BERT okazał się zbyt kosztowny obliczeniowo w protokole $5\text{-fold} \times 4$ domeny (szacowany czas wykonania całego protokołu na lokalnym GPU przekraczał 18 godzin), dlatego rolę silnego transformatorowego *baseline'u* przejął MiniLM.
4. **DistilBERT**, będący wariantem pozwalającym zbadać, czy skompresowany model po transfer learningu zachowuje odporność na zmianę domeny porównywalną z pełnym BERT-em (teza zaczerpnięta z pracy Barbona [17,15]).

Pytania badawcze

W badaniu sformułowano trzy pytania badawcze, z których każde dotyczy innej właściwości metod lub danych i jest weryfikowane odrębnym podzbiorem zaplanowanych eksperymentów:


1. Jak duży jest spadek skuteczności klasyfikacji sentymentu po zmianie domeny (OOD) względem oceny IND? Pytanie dotyczy właściwości *danych* (dystans rozkładów źródłowy–docelowy). Eksperyment: wyliczenie różnic miar *accuracy* oraz *F1 macro* pomiędzy oceną IND a OOD dla każdej komórki pełnej macierzy 4×4 .
2. Czy modele oparte na uwadze (MiniLM, DistilBERT) generalizują lepiej między domenami niż klasyczne podejścia (SVM + TF-IDF, LSTM)? Pytanie dotyczy właściwości *metod* (indukcyjne biasy architektur). Eksperyment: porównanie średnich spadków OOD-vs-IND oraz absolutnych wartości *F1 macro* pomiędzy czterema badanymi architekturami.
3. W jakim stopniu charakterystyka domeny źródłowej (rozmiar zbioru, balans klas) wpływa na zdolność generalizacyjną modelu do pozostałych domen? Pytanie łączy właściwości *danych* i *metod*. Eksperyment: analiza wierszowa macierzy cross-domain, czyli porównanie średniego *F1 macro* OOD osiąganego po treningu na każdej z czterech domen, ze szczególnym uwzględnieniem zbiorów niebalansowanych (Amazon, Yelp) względem zbalansowanych (IMDb, Rotten Tomatoes).

Opis zaimplementowanych metod

Cztery zaimplementowane modele dobrano tak, by pokryć stopniowy gradient skomplikowania reprezentacji języka, od dyskretnej reprezentacji *bag-of-words* aż po pełne dostrajanie modelu Transformerowego. Każdy model został zaimplementowany w niezależnym notatniku Jupyter z izolowanymi zależnościami.

SVM + TF-IDF


Klasyczny statystyczny model bazowy. Reprezentację tekstu stanowi *TfidfVectorizer* ze *scikit-learn* z bigramami (*ngram_range*=(1,2)), z włączonym *sublinear_tf* i ograniczeniem do 50 000 cech. Klasyfikatorem jest *LinearSVC* (*C*=1.0, *class_weight*="balanced", do 5 000 iteracji, *dual*="auto"). Wektoryzator jest dopasowywany niezależnie w każdym foldzie do tekstów treningowych, a na zbiorach testowych OOD stosowana jest jedynie transformacja, co odzwierciedla realistyczny scenariusz wdrożenia.



Rysunek 1. Potok klasyfikacji SVM + TF-IDF.

LSTM


Rekurencyjna sieć neuronowa zaimplementowana w *TensorFlow/Keras*. Architektura: warstwa *Embedding* (rozmiar słownika 20 000, wymiar wektora 128) $\rightarrow$ *LSTM* (128 jednostek ukrytych) $\rightarrow$ *Dropout* (0,5) $\rightarrow$ *Dense*(1, sigmoid). Tokenizator *Keras Tokenizer* jest wspólny dla wszystkich domen, długość sekwencji obcinana jest do 95. percentyla długości w danej domenie. Optymalizacja: *Adam*, funkcja straty *binary crossentropy*, rozmiar batcha 64, do 20 epok treningu z mechanizmem *EarlyStopping*.



Rysunek 2. Potok klasyfikacji LSTM (kolejność warstw od wejścia tekstowego do prawdopodobieństwa klasy pozytywnej).

MiniLM (zamrożony enkoder + regresja logistyczna)


Lekki Transformer zdaniowy w trybie ekstraktora cech. Wykorzystano model *sentence-transformers/all-MiniLM-L6-v2* [18,14] z *max_seq_length=256*, zwracający 384-wymiarowe znormalizowane embeddingi zdań. Na ich podstawie trenowana jest *LogisticRegression* (*liblinear*, *class_weight="balanced"*, do 5 000 iteracji). Embeddingi są obliczane raz dla każdej domeny i reużywane we wszystkich foldach, co znacząco redukuje czas eksperymentu względem fine-tuningu Transformera *end-to-end*.



Rysunek 3. Potok klasyfikacji MiniLM: zamrożony enkoder zdaniowy dostarcza embeddingi, na których trenowana jest regresja logistyczna.

DistilBERT (fine-tuning)

Pełne dostrojenie zdestylowanej wersji modelu BERT (*distilbert-base-uncased*, 6 warstw, $\sim 66\text{M}$ parametrów) [15] z biblioteki *Hugging Face Transformers*. Wejście tokenizowane do długości 128. Optymalizacja: *AdamW* z $\eta = 2 \times 10^{-5}$, rozmiar batcha 32, do 3 epok z *early stopping* o cierpliwości 2.



Rysunek 4. Potok klasyfikacji DistilBERT z pełnym dostrajaniem (*end-to-end*) - w przeciwieństwie do MiniLM aktualizowane są wszystkie wagi enkodera.

Protokół ewaluacji cross-domain

Każdy z czterech modeli był trenowany niezależnie dla każdej z czterech domen, dając pełną macierz 4×4 par (domena treningowa, domena testowa). Stosowana jest 5-krotna walidacja krzyżowa (*StratifiedKFold* dla SVM, MiniLM i DistilBERT; *KFold* dla LSTM, ze względu na uwarunkowania implementacyjne potoku treningowego), z ustalonym ziarnem losowości *random_state*=42 dla powtarzalności.

W każdym z 5 foldów, po wytrenowaniu modelu na części treningowej domeny źródłowej, przeprowadzane są dwie ewaluacje:

- **In-domain (IND)**: na wydzielonej części walidacyjnej tej samej domeny;
- **Out-of-domain (OOD)**: na całych pozostałych trzech zbiorach (przy zachowaniu wektoryzatora / tokenizatora / wag modelu dopasowanych do domeny źródłowej).

Daje to 80 punktów pomiarowych na każdy z czterech modeli (4 domeny treningowe $\times$ [1 IND + 3 OOD] domeny testowe $\times$ 5 foldów). Mierzone metryki to: *accuracy*, *precision*, *recall* oraz *F1* (uśrednienie *macro*, dające równą wagę klasie pozytywnej i negatywnej, co jest istotne wobec niezbalansowania zbiorów Amazon i Yelp). Zachowanie wyników na poziomie pojedynczego folda umożliwia podczas dalszej analizy zbadanie istotności statystycznej zaobserwowanych różnic.

Środowisko badawcze i artefakty

Eksperymenty zaimplementowano w Pythonie 3.13 (zarządzanie zależnościami przez *uv*), w czterech niezależnych notatnikach Jupyter (po jednym na model), w celu izolacji łańcuchów zależności pomiędzy klasycznym *stackiem* *scikit-learn*, *TensorFlow/Keras* oraz *PyTorch + Hugging Face*. Wykorzystane biblioteki: *scikit-learn* (SVM, regresja logistyczna, walidacja krzyżowa i metryki), *TensorFlow/Keras* (LSTM), *Hugging Face Transformers* z *PyTorch* (DistilBERT), *sentence-transformers* (MiniLM). Wszystkie przetworzone zbiory danych, wytrenowane modele LSTM, dzienniki treningu (*training_logs.csv*) oraz pełne wyniki cross-domain (*ood_results.csv*) są wersjonowane w repozytorium projektu, co zapewnia pełną powtarzalność eksperymentów na potrzeby dalszych analiz.

Literatura

1. Ilseyar Alimova, Elena Tutubalina, and Sergey I. Nikolenko. Cross-domain limitations of neural models on biomedical relation classification. *IEEE Access*, 10:1432–1439, 2022.
2. George Chrysostomou and Nikolaos Aletras. An empirical study on explanations in out-of-domain settings, 2022.
3. Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
4. Barry Haddow and Philipp Koehn. Analysing the effect of out-of-domain data on SMT systems. In Chris Callison-Burch, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, and Lucia Specia, editors, *Proceedings of the Seventh Workshop on Statistical Machine Translation*, pages 422–432, Montréal, Canada, June 2012. Association for Computational Linguistics.
5. Hal Daumé III and Daniel Marcu. Domain adaptation for statistical classifiers. *CoRR*, abs/1109.6341, 2011.
6. Di Jin, Shuyang Gao, Seokhwan Kim, Yang Liu, and Dilek Hakkani-Tür. Towards textual out-of-domain detection without in-domain labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:1386–1395, 2022.
7. Matthew Kolodner and Jack Xiao. Evaluating deep learning approaches for out-of-domain land cover classification. 2022.
8. Hao Lang, Yinhe Zheng, Yixuan Li, Jian Sun, Fei Huang, and Yongbin Li. A survey on out-of-distribution detection in nlp, 2023.
9. Stefano Leone. Rotten tomatoes movies and critic reviews dataset. <https://www.kaggle.com/datasets/stefanoleone992/rotten-tomatoes-movies-and-critic-reviews-dataset>. Dostęp: 2026-03-26.
10. Peerat Limkonchotiwat, Wannaphong Phatthiyaphaibun, Raheem Sarwar, Ekapol Chuangsuwanich, and Sarana Nutanong. Handling cross- and out-of-domain samples in thai word segmentation. In *Findings*, 2021.
11. Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostęp: 2026-03-26.
12. Matteo Muffo and Enrico Bertino. Bertino: an italian distilbert model, 2023.
13. Oday Oday, Vijay Madaan, Rajaa Daami Resen, Neha Sharma, Oday Ali Hassen, and Jamal kh kh madhloom. Text categorization for information retrieval using nlp models. *Journal of Cybersecurity and Information Management*, 2025.
14. Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, November 2019.
15. Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter, 2019.
16. Manan Sharma. A comparative analysis of natural language processing models: Bert and lstm in enhancing business communication. *International Journal of Innovative Science and Research Technology*, 2025.
17. Rafael Silva Barbon and Ademar Takeo Akabane. Towards transfer learning techniques—bert, distilbert, bertimbau, and distilbertimbau for automatic text classification from different languages: A case study. *Sensors*, 22(21), 2022.

18. Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers, 2020.
19. Linyi Yang, Yaoxiao Song, Xuan Ren, Chenyang Lyu, Yidong Wang, Lingqiao Liu, Jindong Wang, Jennifer Foster, and Yue Zhang. Out-of-distribution generalization in text classification: Past, present, and future, 2023.
20. Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostęp: 2026-03-26.
21. Shengkai Yuan. Empirical study on the effectiveness of distilbert fine-tuning on imdb sentiment classification outperforming cnn/lstm. *Academic Journal of Science and Technology*, 2026.
22. Yinhe Zheng, Guanyi Chen, and Minlie Huang. Out-of-domain detection for natural language understanding in dialog systems. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:1198–1209, 2020.