

Analiza cross-domain klasyfikacji sentymentu tekstu dla modeli SVM + TF-IDF, LSTM, MiniLM i DistilBERT

Selega Kamil (288780),
Sielska Małgorzata (266560),
Szczepaniak Katarzyna (261895),
Szeląg Magdalena (266857)

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji (W4N)
Kierunek: Zaufane Systemy Sztucznej Inteligencji (TAI)
Kurs: Przetwarzanie Języka Naturalnego

Wprowadzenie

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (z ang. *out-of-domain text classification*, OOD). Głównym celem ewaluacji jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z zupełnie innego źródła. Spadek skuteczności w docelowym środowisku jest powszechnym problemem, dlatego celem pracy jest mierzalna, statystyczna weryfikacja utraty zdolności generalizacyjnych (przy użyciu metryk *accuracy* i *F1*) na zadaniu analizy sentymentu.

Studium literaturowe

Problem generalizacji modeli na dane spoza domeny treningowej od dawna stanowi jedno z większych wyzwań przetwarzania języka naturalnego. Ramy teoretyczne tego zjawiska opisują m.in. Yang i in. [20] oraz Lang i in. [8]. Zwracają oni uwagę, że pomimo świetnych wyników współczesnych sieci neuronowych w obrębie znanych danych docelowych (in-domain), skuteczność klasyfikacji drastycznie spada przy zetknięciu z innym kontekstem wypowiedzi. Systematyczny przegląd metod *nienadzorowanej adaptacji domenowej* dla głębokiego NLP przedstawiają Ramponi i Plank [14], którzy porządkują rodziny rozwiązań (model-centric, data-centric, hybrid) i pokazują, że nawet przy nowoczesnych architekturach Transformerowych spadek OOD pozostaje wyraźny i wymaga celowanych technik kompensujących. Początki prób przeciwdziałania temu zjawisku sięgają klasycznej adaptacji domenowej nakierowanej jeszcze na stare klasyfikatory statystyczne, co analizowali chociażby Daumé III i Marcu [5]. Wraz z narastającym skomplikowaniem sieci, uwaga analityków przesunęła się m.in. na rozpoznawanie nowych intencji z ujęciem metod nienadzorowanych (bez etykiet nowej domeny) [6] czy

ugruntowanie pewności i bezpieczeństwa najnowszych zautomatyzowanych chatbotów konwersacyjnych [23].

Trudności z generalizacją na dane spoza domeny wymuszają nowe metody analiz w zróżnicowanych gałęziach NLP: obniżają jakość tłumaczenia maszynowego [4], ograniczają ekstrakcję encji (ang. *named entity recognition*) podczas analiz tekstów medycznych [1], a nawet generują szum decyzyjny przy segmentowaniu izolowanych tekstów języków azjatyckich przeplatanych wtrąceniami europejskimi [10]. Zjawisko wykracza daleko poza ramy NLP i dotyczy też kategoryzacji obrazów wizyjnych, chociażby klasyfikacji środowiska na podstawie rzutów satelitarnych [7].

Obok głębokich ujęć rekurencyjnych (LSTM) standardami w zadaniach kategoryzacji zdań i wyszukiwania tekstu stały się od niedawna reprezentacje oparte natywnie na mechanizmie uwagi (Transformer, m.in. popularny BERT). Szerokiej weryfikacji takich architektur podjęli się badawczo i polecają takie metody m.in. Sharma [17] oraz Oday i in. [13]. Istotną luką pozostaje jednak ograniczanie rozmiaru tych modeli. Stąd naukowcy zwrócili się ku mniejszym, ale zoptymalizowanym przez transfer learning wersjom tych samych modeli, na czele z DistilBERT-em. Barbon i Akabane [18] potwierdzili badawczo wysoką, często zaskakującą skuteczność lekkiego DistilBERT-a w niwelowaniu różnic między domenami w analizach wielojęzycznych w porównaniu do starszych architektur klasyfikacyjnych; podobne wnioski przedstawili Muffo i Bertino, testując zjawisko na dużych zasobach tekstowych dla języka włoskiego [12]. Co najważniejsze z perspektywy badanego w tym projekcie problemu, Yuan [22] potwierdził na zbiorach IMDb skuteczność lekkiej wersji DistilBERT, wykazując przewagę klasyfikacji opartej na Transformerze nad klasycznymi sieciami głębokimi (CNN i LSTM). Jednocześnie warto wspomnieć, że badając tak złożone architektury należy posługiwać się decyzjami popartymi jasnymi wyjaśnieniami (ang. *explanations*), co dla modeli OOD szerzej wykazali Chrysostomou i Aletras [2].

Plan eksperymentu

Opierając się na powyższym przeglądzie, zdecydowano się przetestować algorytmy na zadaniu klasyfikacji sentymentu stosując ewaluację międzydomenową (ang. *cross-domain*). Zamiast ustalać wyłącznie jedną domenę bazową, każda z zademonstrowanych architektur będzie trenowana niezależnie dla każdego poszczególnego zbioru danych. Po wytrenowaniu modelu na danym zbiorze (źródłowym), zostanie on przetestowany na nim samym (ewaluacja *in-domain*, dalej IND) oraz na każdym z pozostałych (ewaluacja *out-of-domain*, dalej OOD). Badanie rotacyjnie obejmie poniższe zbiory:

- **IMDb Dataset:** 50 000 recenzji filmowych, zbalansowane (25 000 / 25 000); etykiety z pola *sentiment*. Często używane jako bazowy punkt odniesienia jakości modeli głębokich w analizie sentymentu [22,11].
- **Rotten Tomatoes Dataset:** oryginalny zbiór zawiera ponad 1,1 mln recenzji krytyków o silnie niezbalansowanym rozkładzie etykiet i bardzo zróżnicowanych długościach. Aby uzyskać porównywalność z IMDb pod kątem

rozmiaru i balansu klas (kluczową przy izolowaniu efektu *domeny* od efektu *ilości danych* w RQ3), losowo (*random_state=42*) podpróbkowano 50 000 recenzji zrównoważonych klasowo (25 000 / 25 000); etykiety z pola *review_type*: *fresh*→1, *rotten*→0 [9].

- **Amazon Reviews Dataset**: 21 055 recenzji produktów, niebalansowane (6 705 pozytywnych / 14 350 negatywnych); etykiety z pola *Rating* (ocena ≥ 3 oznacza recenzję pozytywną) [3].
- **Yelp Reviews**: 10 000 recenzji lokalnych usług, niebalansowane (8 324 pozytywne / 1 676 negatywnych); etykiety z pola *stars* (ocena ≥ 3 oznacza recenzję pozytywną) [21].

Wszystkie teksty przetworzono wspólnym potokiem czyszczącym: konwersja do małych liter, usunięcie znaczników HTML, adresów URL, znaków niealfabetycznych oraz normalizacja białych znaków. Niebalansowanie zbiorów Amazon i Yelp zostało świadomie zachowane, co stanowi materiał do trzeciego pytania badawczego. Dzięki zbudowaniu pełnej macierzy testowej (każdy model trenowany kolejno na jednej z czterech domen i testowany na wszystkich czterech) badanie pozwoli zmierzyć, w jakim stopniu zmiana domeny wpływa na parametry dokładności modeli, których tło teoretyczne opisują Yang i Lang [20,8]. W ramach protokołów testowych przyjmuje się rygorystyczny podział każdego ze środowisk danych. Aby zapewnić wiarygodność doboru hiperparametrów i uniknąć przetrenowania na zbiorze źródłowym, na etapie treningu zastosowana zostanie *k*-krotna walidacja krzyżowa (ang. *k-fold cross-validation*). Finalna ewaluacja każdego modelu przeprowadzona zostanie natomiast na wydzielonych zbiorach testowych, zarówno IND, jak i OOD, co umożliwi miarodajne i statystycznie poprawne porównania cross-domain.

Do weryfikacji celów postawiono na zróżnicowany stack algorytmiczny, aby porównać skuteczność pomiędzy starymi standardami klasyfikacyjnymi i innowacyjnym użyciem uwag i transformatorów [5,18]. Posłużą temu cztery stopnie trudności badanej architektury:

1. **SVM + wektoryzacja TF-IDF**, reprezentująca optymalny wczesny model z nurtu klasyfikatorów statystycznych, tworząca próg bazowego startu eksperymentu.
2. **LSTM**, stanowiący stabilniejszy, bazowy standard przetwarzania, nierzadko słabszy od modeli Transformerowych na danych spoza domeny, co Yuan [22] wskazuje jako punkt odniesienia do pomiaru siły tych różnic.
3. **MiniLM (sentence-transformers)**, czyli lekki transformator zdaniowy używany w trybie zamrożonym jako ekstraktor cech, stanowiący kompromis pomiędzy klasycznym LSTM a pełnym dostrajaniem modeli językowych [19,15]. Pierwotnie planowany w jego miejscu pełny BERT okazał się zbyt kosztowny obliczeniowo w protokole 5-fold $\times$ 4 domeny (szacowany czas wykonania całego protokołu na lokalnym GPU przekraczał 18 godzin), dlatego rolę silnego transformatorowego *baseline'u* przejął MiniLM.
4. **DistilBERT**, będący wariantem pozwalającym zbadać, czy skompresowany model po transfer learningu zachowuje odporność na zmianę domeny porównywalną z pełnym BERT-em (teza zaczerpnięta z pracy Barbona [18,16]).

Pytania badawcze

W badaniu sformułowano trzy pytania badawcze, z których każde dotyczy innej właściwości metod lub danych i jest weryfikowane odrębnym podzbiorem zaplanowanych eksperymentów:

- RQ 1.** Jak duży jest spadek skuteczności klasyfikacji sentymentu po zmianie domeny (OOD) względem oceny IND? Pytanie dotyczy właściwości *danych* (dystans rozkładów źródłowy–docelowy). Eksperyment: wyliczenie różnic miar *accuracy* oraz *F1 macro* pomiędzy oceną IND a OOD dla każdej komórki pełnej macierzy 4×4 .
- RQ 2.** Czy modele oparte na uwadze (MiniLM, DistilBERT) generalizują lepiej między domenami niż klasyczne podejścia (SVM + TF-IDF, LSTM)? Pytanie dotyczy właściwości *metod* (indukcyjne biasy architektur). Eksperyment: porównanie średnich spadków OOD-vs-IND oraz absolutnych wartości *F1 macro* pomiędzy czterema badanymi architekturami.
- RQ 3.** W jakim stopniu charakterystyka domeny źródłowej (rozmiar zbioru, balans klas) wpływa na zdolność generalizacyjną modelu do pozostałych domen? Pytanie łączy właściwości *danych* i *metod*. Eksperyment: analiza wierszowa macierzy cross-domain, czyli porównanie średniego *F1 macro* OOD osiąganego po treningu na każdej z czterech domen, ze szczególnym uwzględnieniem zbiorów niezbalansowanych (Amazon, Yelp) względem zbalansowanych (IMDb, Rotten Tomatoes).

Opis zaimplementowanych metod


Cztery zaimplementowane modele dobrano tak, by pokryć stopniowy gradient skomplikowania reprezentacji języka, od dyskretnej reprezentacji *bag-of-words* aż po pełne dostrajanie modelu Transformerowego. Każdy model został zaimplementowany w niezależnym notatniku Jupyter z izolowanymi zależnościami.

SVM + TF-IDF

Klasyczny statystyczny model bazowy. Reprezentację tekstu stanowi *TfidfVectorizer* ze *scikit-learn* z bigramami (*ngram_range*=(1,2)), z włączonym *sublinear_tf* i ograniczeniem do 50 000 cech. Klasyfikatorem jest *LinearSVC* (*C*=1.0, *class_weight*="balanced", do 5 000 iteracji, *dual*="auto"). Wektoryzator jest dopasowywany niezależnie w każdym foldzie do tekstów treningowych, a na zbiorach testowych OOD stosowana jest jedynie transformacja, co odzwierciedla realistyczny scenariusz wdrożenia.


LSTM

Rekurencyjna sieć neuronowa zaimplementowana w *TensorFlow/Keras*. Architektura: warstwa *Embedding* (rozmiar słownika 20 000, wymiar wektora 128) →



Rysunek 1. Potok klasyfikacji SVM + TF-IDF.


LSTM (128 jednostek ukrytych) $\rightarrow$ *Dropout* (0,5) $\rightarrow$ *Dense*(1, sigmoid). Tokenizator *Keras Tokenizer* jest wspólny dla wszystkich domen, długość sekwencji obcinana jest do 95. percentyla długości w danej domenie. Optymalizacja: *Adam*, funkcja straty *binary crossentropy*, rozmiar batcha 64, do 20 epok treningu z mechanizmem *EarlyStopping*.



Rysunek 2. Potok klasyfikacji LSTM (kolejność warstw od wejścia tekstowego do prawdopodobieństwa klasy pozytywnej).

MiniLM (zamrożony enkoder + regresja logistyczna)


Lekki Transformer zdaniowy w trybie ekstraktora cech. Wykorzystano model *sentence-transformers/all-MiniLM-L6-v2* [19,15] z *max_seq_length=256*, zwracający 384-wymiarowe znormalizowane embeddingi zdań. Na ich podstawie trenowana jest *LogisticRegression* (*liblinear*, *class_weight="balanced"*, do 5 000 iteracji). Embeddingi są obliczane raz dla każdej domeny i reużywane we wszystkich foldach, co znacząco redukuje czas eksperymentu względem fine-tuningu Transformera *end-to-end*.



Rysunek 3. Potok klasyfikacji MiniLM: zamrożony enkoder zdaniowy dostarcza embeddingi, na których trenowana jest regresja logistyczna.

DistilBERT (fine-tuning)

Pełne dostrojenie zdestylowanej wersji modelu BERT (*distilbert-base-uncased*, 6 warstw, $\sim 66\text{M}$ parametrów) [16] z biblioteki *Hugging Face Transformers*. Wejście tokenizowane do długości 128. Optymalizacja: *AdamW* z $\eta = 2 \times 10^{-5}$, rozmiar batcha 32, do 3 epok z *early stopping* o cierpliwości 2.



Rysunek 4. Potok klasyfikacji DistilBERT z pełnym dostrajaniem (*end-to-end*) - w przeciwieństwie do MiniLM aktualizowane są wszystkie wagi enkodera.

Protokół ewaluacji cross-domain

Każdy z czterech modeli był trenowany niezależnie dla każdej z czterech domen, dając pełną macierz 4×4 par (domena treningowa, domena testowa). Stosowana jest 5-krotna walidacja krzyżowa (*StratifiedKFold* dla SVM, MiniLM i DistilBERT; *KFold* dla LSTM, ze względu na uwarunkowania implementacyjne potoku treningowego), z ustalonym ziarnem losowości *random_state*=42 dla powtarzalności.

W każdym z 5 foldów, po wytrenowaniu modelu na części treningowej domeny źródłowej, przeprowadzane są dwie ewaluacje:

- **In-domain (IND)**: na wydzielonej części walidacyjnej tej samej domeny;
- **Out-of-domain (OOD)**: na całych pozostałych trzech zbiorach (przy zachowaniu wektoryzatora / tokenizatora / wag modelu dopasowanych do domeny źródłowej).

Daje to 80 punktów pomiarowych na każdy z czterech modeli (4 domeny treningowe $\times$ [1 IND + 3 OOD] domeny testowe $\times$ 5 foldów). Mierzone metryki to: *accuracy*, *precision*, *recall* oraz *F1* (uśrednienie *macro*, dające równą wagę klasie pozytywnej i negatywnej, co jest istotne wobec niezbalansowania zbiorów Amazon i Yelp). Zachowanie wyników na poziomie pojedynczego folda umożliwia podczas dalszej analizy zbadanie istotności statystycznej zaobserwowanych różnic.

Środowisko badawcze i artefakty

Eksperymenty zaimplementowano w Pythonie 3.13 (zarządzanie zależnościami przez *uv*), w czterech niezależnych notatnikach Jupyter (po jednym na model), w celu izolacji łańcuchów zależności pomiędzy klasycznym *stackiem* *scikit-learn*, *TensorFlow/Keras* oraz *PyTorch + Hugging Face*. Wykorzystane biblioteki: *scikit-learn* (SVM, regresja logistyczna, walidacja krzyżowa i metryki), *TensorFlow/Keras* (LSTM), *Hugging Face Transformers* z *PyTorch* (DistilBERT), *sentence-transformers* (MiniLM). Wszystkie przetworzone zbiory danych, wytrenowane modele LSTM, dzienniki treningu (*training_logs.csv*) oraz pełne wyniki cross-domain (*ood_results.csv*) są wersjonowane w repozytorium projektu, co zapewnia pełną powtarzalność eksperymentów na potrzeby dalszych analiz. Agregacja, testy statystyczne oraz wszystkie wykresy zaprezentowane w dalszej

części raportu są generowane przez notatnik `analysis/analysis.ipynb`, a wynikowe tabele i figury zapisywane są odpowiednio do `analysis/tables/` oraz `analysis/figures/`.

Analiza wyników

Pełna macierz cross-domain daje 320 punktów pomiarowych ($4 \text{ modele} \times 4 \text{ domeny treningowe} \times 4 \text{ domeny testowe} \times 5 \text{ foldów}$). Każdy wiersz w pliku wyników reprezentuje pojedynczy fold, a metryki obliczono jako klasyczną *accuracy*, *precision*, *recall* oraz *macro-averaged F1* – w klasie pozytywnej i negatywnej z równą wagą, co jest istotne wobec niezbalansowania zbiorów Amazon i Yelp. Wszystkie agregacje przedstawiane są jako średnia $\pm$ odchylenie standardowe ($\mu \pm \sigma$). W treści analizy posługujemy się głównie macro-F1, ponieważ akumuluje on jednocześnie informację o *precision* i *recall* oraz dobrze odzwierciedla wydajność na obu klasach, niezależnie od ich proporcji w zbiorze testowym.

RQ1 – Spadek skuteczności po zmianie domeny

Tabela 1 zawiera średnie macro-F1 IND oraz OOD wraz z bezwzględną (Δ) i względną (Δ/IND) różnicą dla każdej pary (model, domena treningowa). Spadek po opuszczeniu domeny źródłowej jest *wszechobecny*: dotyka każdego z czterech modeli i właściwie każdej domeny treningowej. Skala spadku jest jednak silnie zróżnicowana – od 6,8% (DistilBERT trenowany na Rotten Tomatoes) do 25,6% (LSTM trenowany na Yelp). Tylko jedna z 16 komórek przyniosła nieznaczną poprawę po zmianie domeny (MiniLM trenowany na Rotten: $-2,1\%$), co wynika z tego, że Rotten Tomatoes jest najtrudniejszą domeną IND (krótkie, ekspresywne recenzje krytyków filmowych) – pozostałe domeny są w tym przypadku łatwiejsze.

Rysunek 5 prezentuje pełną macierz cross-domain dla wszystkich czterech modeli. Najjaśniejsze (najlepsze) pola pojawiają się na przekątnej (oceny IND), a najwyraźniej widoczne ciemne obszary dotyczą par (Amazon $\rightarrow$ Rotten) oraz (Yelp $\rightarrow$ Rotten/Amazon). Wzorzec pionowy w kolumnie *yelp* pokazuje, że wszystkie modele radzą sobie z testem na Yelp stosunkowo dobrze, niezależnie od domeny treningowej. Z kolei wzorzec poziomy w wierszu *yelp* ujawnia, że model uczony na Yelp gorzej generalizuje (zwłaszcza na Rotten i IMDb) – co może być powiązane z dwiema cechami Yelp: najmniejszym rozmiarem zbioru źródłowego oraz silnym niezbalansowaniem klas.

Aby oddzielić bezwzględny poziom F1 (zdominowany przez wartości IND na przekątnej) od wielkości *spadku* przy zmianie domeny, Rysunek 6 prezentuje analogiczną macierz, w której każda komórka pokazuje $\Delta = F1 \text{ IND danej domeny treningowej} - F1 \text{ komórki}$. Z konstrukcji pola na przekątnej dają zero, kolor czerwony odpowiada spadkowi, a niebieski – rzadkim przypadkom *pozytywnego transferu*. Wzorzec ujawnia trzy zjawiska niewidoczne na surowej heatmapie absolutnej: (i) największe spadki (powyżej 0,25 F1) pojawiają się dla par *Amazon*

Tabela 1. Średnie macro-F1 w trybie IND i OOD wraz ze spadkiem Δ dla każdej pary (model, domena treningowa). Wartości IND uśrednione po 5 foldach, OOD dodatkowo po 3 docelowych domenach (15 pomiarów).

Model	Dom. tren.	F1 IND ($\mu \pm \sigma$)	F1 OOD ($\mu \pm \sigma$)	Δ F1	Δ /IND
SVM	IMDb	0.908 $\pm$ 0.002	0.767 $\pm$ 0.104	0.141	15.6%
	Rotten	0.778 $\pm$ 0.005	0.723 $\pm$ 0.112	0.055	7.0%
	Amazon	0.883 $\pm$ 0.004	0.695 $\pm$ 0.162	0.188	21.3%
	Yelp	0.947 $\pm$ 0.004	0.733 $\pm$ 0.040	0.214	22.6%
LSTM	IMDb	0.883 $\pm$ 0.006	0.724 $\pm$ 0.109	0.159	18.0%
	Rotten	0.767 $\pm$ 0.007	0.649 $\pm$ 0.095	0.118	15.4%
	Amazon	0.867 $\pm$ 0.012	0.662 $\pm$ 0.152	0.205	23.6%
	Yelp	0.933 $\pm$ 0.007	0.695 $\pm$ 0.032	0.239	25.6%
MiniLM	IMDb	0.825 $\pm$ 0.002	0.745 $\pm$ 0.139	0.080	9.6%
	Rotten	0.736 $\pm$ 0.008	0.751 $\pm$ 0.100	-0.015	-2.1%
	Amazon	0.848 $\pm$ 0.007	0.778 $\pm$ 0.104	0.071	8.3%
	Yelp	0.895 $\pm$ 0.007	0.686 $\pm$ 0.027	0.210	23.4%
DistilBERT	IMDb	0.884 $\pm$ 0.006	0.810 $\pm$ 0.043	0.075	8.4%
	Rotten	0.845 $\pm$ 0.003	0.788 $\pm$ 0.062	0.057	6.8%
	Amazon	0.893 $\pm$ 0.004	0.771 $\pm$ 0.105	0.122	13.7%
	Yelp	0.945 $\pm$ 0.004	0.765 $\pm$ 0.032	0.180	19.0%

$\rightarrow$ *Rotten* oraz *Yelp* $\rightarrow$ *Rotten/Amazon*, czyli niemal wyłącznie z domen niezbalansowanych do zbalansowanych; (ii) DistilBERT (prawy dolny panel) ma jednoznacznie najjaśniejszą całą macierz, czyli najmniejsze spadki we wszystkich 12 komórkach OOD; (iii) jedyne wyrażenie negatywne Δ (do -0,11) występują dla MiniLM uczonego na zbiorach filmowych i testowanego na Yelp – co dodatkowo potwierdza, że Yelp jest stosunkowo łatwą domeną docelową.

Rysunek 7 podsumowuje średni bezwzględny spadek F1 po zmianie domeny dla każdego modelu (uśrednienie po 4 domenach treningowych). LSTM jest najbardziej wrażliwy na zmianę domeny (średni spadek 0,180), MiniLM najmniej (0,086), natomiast DistilBERT oferuje najwyższe wartości absolutne F1 OOD przy umiarkowanym spadku 0,108. Wartości procentowe nad słupkami wskazują, że dla najsłabszych modeli (LSTM, SVM) zmiana domeny obniża F1 średnio o niemal jedną piątą wartości IND.

Odpowiedź na RQ1. Spadek skuteczności klasyfikacji sentymentu OOD vs IND jest istotny i systematyczny – średnio 13,1% F1 w skali wszystkich modeli (od 8,6% dla MiniLM do 18,0% dla LSTM). Tylko jedna komórka na 16 pokazała neutralny lub pozytywny transfer, co potwierdza tezy literatury [20,8], że generalizacja poza domenę treningową jest poważnym problemem nawet dla nowoczesnych modeli językowych.




Rysunek 5. Średnie macro-F1 (uśrednienie po 5 foldach) w macierzy cross-domain 4×4 dla każdego z modeli. Diagonalna odpowiada ewaluacji IND, pola poza nią – OOD.

RQ2 – Porównanie architektur klasycznych i uwagowych

Tabela 2 prezentuje ranking modeli po średnim macro-F1 OOD (60 pomiarów per model: 4 domeny treningowe $\times$ 3 OOD domeny testowe $\times$ 5 foldów). Pierwsze miejsce zajmuje **DistilBERT** ($0,783 \pm 0,067$), wyraźnie wyprzedzając MiniLM ($0,740$), SVM + TF-IDF ($0,730$) i LSTM ($0,682$). Co szczególnie warto uwagi, DistilBERT ma także najmniejsze odchylenie standardowe – jest nie tylko najwyżej notowany, ale i najbardziej stabilny między parami domen.

Istotność różnic między modelami sprawdzono na poziomie pojedynczego folda. Dla każdej pary modeli przygotowano 60 dopasowanych obserwacji (każda para (`train_domain`, `test_domain`, `fold`) OOD pojawia się raz w każdym modelu). Zastosowano **sparowany test t-Studenta** oraz pomocniczo test Wilcoxona (odporny na łamanie założenia normalności). Dla 6 możliwych par modeli ($C(4,2)$) zastosowano korektę Bonferroniego. Wyniki zebrano w tabeli 3.

Wyniki testów potwierdzają, że *wszystkie* różnice z udziałem DistilBERT-a i LSTM-a są istotne na poziomie $p < 0,001$ nawet po konserwatywnej korekcie Bonferroniego. Jednocześnie różnica między SVM a MiniLM jest *nieistotna*.




Rysunek 6. Spadek macro-F1 ($\Delta = \text{F1 IND} - \text{F1 komórki}$) w macierzy cross-domain dla każdego modelu. Czerwone pola oznaczają spadek przy zmianie domeny, niebieskie – pozytywny transfer, pola na przekątnej z definicji są zerowe.

($p_{Bonf} = 1,000$), co stanowi główne odkrycie tego pytania badawczego: **zamrożony enkoder MiniLM użyty z regresją logistyczną statystycznie nie wyróżnia się na tle dobrze dobranego klasycznego SVM + TF-IDF**. Dopiero pełne dostrojenie (DistilBERT) wykorzystuje w pełni potencjał reprezentacji opartych na uwadze.

Boxplot na rys. 8 obrazuje pełną dystrybucję F1 OOD per model. Pudełko DistilBERT-a jest najwęższe i przesunięte najwyżej; wyraźnie widać szeroki rozrzut wyników LSTM-a (zawierający kilka dramatycznie słabych pomiarów $\text{F1} < 0,55$).

Odpowiedź na RQ2. **Częściowo tak** – pełne dostrajanie modelu opartego na uwadze (DistilBERT) generalizuje statystycznie istotnie lepiej od wszystkich pozostałych podejść, ze znacząco mniejszą wariancją. Niemniej *sama* obecność mechanizmu uwagi nie wystarcza: zamrożony MiniLM jako ekstraktor cech osiąga wyniki nieodróżnialne statystycznie od klasycznego SVM + TF-IDF. Krytyczny



Rysunek 7. Średni spadek macro-F1 przy zmianie domeny (IND – OOD), uśredniony po 4 domenach treningowych. Etykiety nad słupkami pokazują względny spadek Δ/IND .

Tabela 2. Ranking modeli po średnim macro-F1 OOD (60 pomiarów). Spadek Δ liczony jako średnie F1 IND – średnie F1 OOD.

Model	F1 IND (μ)	F1 OOD ($\mu \pm \sigma$)	Mediana F1 OOD	Spadek Δ
SVM	0.879	0.730 ± 0.113	0.737	0.149
LSTM	0.862	0.682 ± 0.108	0.684	0.180
MiniLM	0.826	0.740 ± 0.104	0.724	0.086
DistilBERT	0.892	0.783 ± 0.067	0.786	0.108

okazuje się sposób użycia transformera – dopiero *fine-tuning* przekłada się na realny zysk OOD, zgodnie z obserwacjami w [22,18].

RQ3 – Wpływ charakterystyki domeny źródłowej


Tabela 4 zestawia średnie macro-F1 OOD per (model, domena treningowa) wraz z informacją o rozmiarze i zbalansowaniu zbioru źródłowego, a tabela 5 agreguje to do dwóch klas: zbalansowane (IMDb, Rotten Tomatoes – po 50 000 przykładów) oraz niezbalansowane (Amazon – 21 055, Yelp – 10 000).

Każdy z czterech modeli osiąga *nieznacznie wyższe* średnie F1 OOD po treningu na domenie zbalansowanej – różnica wynosi od ok. 0,009 dla LSTM do 0,031 dla DistilBERT. Co ciekawe, DistilBERT równocześnie dramatycznie obniża σ przy treningu na zbalansowanym zbiorze (0,054 vs 0,077), co sugeruje, że duży zbalansowany korpus stabilizuje fine-tuning.

Rysunek 9 pokazuje rozkład F1 OOD per domena treningowa i model. Najbardziej spektakularny wynik to przewaga **DistilBERT-a uczonego na IMDb** (0,810) – to jedyna kombinacja, dla której średnia F1 OOD przekracza 0,80. W przypadku najmniejszego zbioru (Yelp, 10 000 przykładów) widać efekt rozmiaru:

Tabela 3. Sparowane testy istotności różnicy macro-F1 OOD między parami modeli. $\Delta F1$ oznacza średnią różnicę (Model A – Model B); ujemne wartości oznaczają przewagę Modelu B. Gwiazdki: * $p < 0,05$, ** $p < 0,01$, *** $p < 0,001$ (po korekcie Bonferroniego, $n = 60$ par foldów).

Model A	Model B	$\Delta F1$	p (t-test)	p (t, Bonf.)	p (Wilcoxon)	p (W, Bonf.)
SVM	LSTM	0.047	<0.001	<0.001***	<0.001	<0.001***
SVM	MiniLM	-0.010	0.246	1.000	0.517	1.000
SVM	DistilBERT	-0.054	<0.001	<0.001***	<0.001	<0.001***
LSTM	MiniLM	-0.058	<0.001	<0.001***	<0.001	<0.001***
LSTM	DistilBERT	-0.101	<0.001	<0.001***	<0.001	<0.001***
MiniLM	DistilBERT	-0.043	<0.001	<0.001***	<0.001	<0.001***



Rysunek 8. Rozkład macro-F1 OOD dla każdego z modeli (60 pomiarów per model). Punkty w tle pokazują pojedyncze foldy.

wszystkie modele dają najsłabsze wyniki OOD przy najniższym σ (konsekwentnie słabo).

Odpowiedź na RQ3. Charakterystyka domeny źródłowej wpływa na generalizację, ale efekt jest niewielki i drugorzędny w porównaniu z wyborem architektury (RQ2). Trening na większym i zbalansowanym zbiorze (IMDb, Rotten) daje konsekwentnie lekko lepsze F1 OOD niż trening na mniejszym i niezbalansowanym (Amazon, Yelp); różnice mieszczą się w zakresie 1–3 punktów F1. Najbardziej widoczna jest *stabilizacja* – DistilBERT po treningu na zbalansowanym zbiorze zachowuje wąski rozrzut F1 OOD pomiędzy testowymi domenami.

Wnioski i podsumowanie

Przeprowadzona ewaluacja cross-domain potwierdza, że **spadek skuteczności klasyfikacji sentymentu po zmianie domeny jest zjawiskiem powszech-**

Tabela 4. Średnie macro-F1 OOD per (model, domena treningowa) z charakterystyką zbioru źródłowego.

Model	Domena tren.	Balans	Rozmiar	F1 OOD ($\mu \pm \sigma$)
SVM	IMDb	zbalansowana	50000	0.767 ± 0.104
	Rotten	zbalansowana	50000	0.723 ± 0.112
	Amazon	niezbalansowana	21055	0.695 ± 0.162
	Yelp	niezbalansowana	10000	0.733 ± 0.040
LSTM	IMDb	zbalansowana	50000	0.724 ± 0.109
	Rotten	zbalansowana	50000	0.649 ± 0.095
	Amazon	niezbalansowana	21055	0.662 ± 0.152
	Yelp	niezbalansowana	10000	0.695 ± 0.032
MiniLM	IMDb	zbalansowana	50000	0.745 ± 0.139
	Rotten	zbalansowana	50000	0.751 ± 0.100
	Amazon	niezbalansowana	21055	0.778 ± 0.104
	Yelp	niezbalansowana	10000	0.686 ± 0.027
DistilBERT	IMDb	zbalansowana	50000	0.810 ± 0.043
	Rotten	zbalansowana	50000	0.788 ± 0.062
	Amazon	niezbalansowana	21055	0.771 ± 0.105
	Yelp	niezbalansowana	10000	0.765 ± 0.032


Tabela 5. Średnie macro-F1 OOD w podziale na zbalansowanie domeny treningowej.

Model	Klasa domen trenujących	F1 OOD ($\mu \pm \sigma$)
SVM	niezbalansowana	0.714 ± 0.118
	zbalansowana	0.745 ± 0.108
LSTM	niezbalansowana	0.678 ± 0.110
	zbalansowana	0.687 ± 0.107
MiniLM	niezbalansowana	0.732 ± 0.088
	zbalansowana	0.748 ± 0.119
DistilBERT	niezbalansowana	0.768 ± 0.077
	zbalansowana	0.799 ± 0.054

nym i istotnym – średnio 13,1 punktu macro-F1 między ewaluacją IND a OOD. Skala spadku rośnie wraz ze spadkiem złożoności i pojemności modelu: najbardziej narażone są klasyczne reprezentacje rekurencyjne (LSTM, średnio -18%) oraz statystyczne (SVM + TF-IDF, -15%). Modele oparte na uwadze radzą sobie lepiej, ale dopiero pełne dostrojenie sieci (DistilBERT, $-10,8\%$) daje statystycznie istotną przewagę nad wszystkimi pozostałymi podejściami.

Najważniejsze wnioski analityczne:

- **Hierarchia architektur na danych OOD jest stabilna** i wynosi w kolejności malejącej macro-F1: DistilBERT ($0,783$) > MiniLM ($0,740$) $\approx$ SVM ($0,730$) > LSTM ($0,682$). Wszystkie różnice są istotne ($p_{Bonf} < 0,001$) z wyjątkiem pary MiniLM–SVM. Sygnalizuje to, że samo zamrożone reprezentowanie tekstu jako embeddingu zdaniowego nie wystarcza, jeśli model nie zostanie dostrojony do zadania.



Rysunek 9. Średnie macro-F1 OOD per domena treningowa (uśrednione po 3 docelowych domenach $\times$ 5 foldach). Czerwone i pogrubione etykiety oznaczają domeny niebalansowane.

- **DistilBERT łączy najwyższe F1 OOD z najmniejszą wariancją.** Spośród wszystkich modeli ma także najmniejszy rozstęp pomiędzy parami (train, test) – co jest pożądaną cechą w praktyce wdrożeniowej, gdzie domena docelowa bywa nieznana.
- **Wpływ charakterystyki domeny źródłowej jest drugorzędny.** Rozmiar i zbalansowanie zbioru treningowego dają ok. 1–3 punktów F1 przewagi dla zbalansowanych zbiorów IMDb/Rotten nad niebalansowanymi Amazon/Yelp. Sygnał jest jednak konsekwentny w 4 z 4 testowanych architektur.
- **Najtrudniejsza domena docelowa to Rotten Tomatoes.** Krótkie, ekspresywne recenzje krytyków filmowych okazują się przewidywalnie trudne także w trybie IND, co czyni je dobrym sprawdzianem odporności reprezentacji.

Ograniczenia i zagrożenia dla wniosków

Należy mieć na uwadze następujące zastrzeżenia:

- Liczba foldów ($k = 5$) jest umiarkowana; przy 60 sparowanych obserwacjach moc sparowanego testu t jest dobra, ale dla mniejszych podzbiorów (np. RQ1 na poziomie pojedynczej komórki, $n = 5$) interpretacja σ jest ostrożna.
- Z planowanej palety zrezygnowano z pełnego BERT-a na rzecz MiniLM ze względu na koszt obliczeniowy; ostateczne porównanie obejmuje skompresowane modele (DistilBERT, MiniLM) bez bazowego transformera.
- **Asymetria paradygmatów dla modeli uwagowych.** MiniLM wykorzystano w trybie zamrożonym (embedding + regresja logistyczna), podczas gdy

DistilBERT-a poddano pełnemu dostrojeniu (*end-to-end fine-tuning*). RQ2 jest więc w istocie testem *dwóch różnych paradygmatów użycia* architektur uwagowych, a nie czystym porównaniem samych *architektur*: jednego enkodera użytego jako gotowy ekstraktor cech vs jednego modelu dostrajanego do zadania docelowego. Implikuje to dwa zastrzeżenia interpretacyjne:

- Obserwowana statystyczna nieistotność różnicy *MiniLM vs SVM* ($p_{Bonf} = 1,000$) odnosi się wyłącznie do konfiguracji *frozen embeddings + LogReg* – nie należy z niej wnioskować, że MiniLM jako *model* nie ma przewagi nad TF-IDF.
 - Obserwowana statystyczna przewaga *DistilBERT vs MiniLM* ($p_{Bonf} < 0,001$) miesza dwa efekty: (i) większą pojemność architektury DistilBERT-a oraz (ii) zysk wynikający z dostrajania zadaniowego. Rozłączenie tych efektów wymagałoby uzupełnienia macierzy o dostrojony MiniLM oraz zamrożony DistilBERT.
- Tekst Amazon i Yelp jest niezbalansowany w stronę klasy pozytywnej. Mimo użycia macro-F1 i mechanizmów wagowych (*class_weight="balanced"* dla SVM, MiniLM oraz balansowania batchy dla DistilBERT) może występować systematyczna preferencja dla klasy większościowej, szczególnie widoczna w wysokim *recall* przy umiarkowanym *precision* (zob. surowe CSV).
- Wybór sekwencji o długości 128 dla DistilBERT-a obcina ogony długich recenzji IMDb; dłuższe okno mogłoby poprawić wyniki, ale podnieść koszt treningu.

Literatura

1. Ilseyar Alimova, Elena Tutubalina, and Sergey I. Nikolenko. Cross-domain limitations of neural models on biomedical relation classification. *IEEE Access*, 10:1432–1439, 2022.
2. George Chrysostomou and Nikolaos Aletras. An empirical study on explanations in out-of-domain settings, 2022.
3. Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
4. Barry Haddow and Philipp Koehn. Analysing the effect of out-of-domain data on SMT systems. In Chris Callison-Burch, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, and Lucia Specia, editors, *Proceedings of the Seventh Workshop on Statistical Machine Translation*, pages 422–432, Montréal, Canada, June 2012. Association for Computational Linguistics.
5. Hal Daumé III and Daniel Marcu. Domain adaptation for statistical classifiers. *CoRR*, abs/1109.6341, 2011.
6. Di Jin, Shuyang Gao, Seokhwan Kim, Yang Liu, and Dilek Hakkani-Tür. Towards textual out-of-domain detection without in-domain labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:1386–1395, 2022.
7. Matthew Kolodner and Jack Xiao. Evaluating deep learning approaches for out-of-domain land cover classification. 2022.
8. Hao Lang, Yinhe Zheng, Yixuan Li, Jian Sun, Fei Huang, and Yongbin Li. A survey on out-of-distribution detection in nlp, 2023.

9. Stefano Leone. Rotten tomatoes movies and critic reviews dataset. <https://www.kaggle.com/datasets/stefanoleone992/rotten-tomatoes-movies-and-critic-reviews-dataset>. Dostęp: 2026-03-26.
10. Peerat Limkonchotiwat, Wannaphong Phatthiyaphaibun, Raheem Sarwar, Ekapol Chuangsuwanich, and Sarana Nutanong. Handling cross- and out-of-domain samples in thai word segmentation. In *Findings*, 2021.
11. Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostęp: 2026-03-26.
12. Matteo Muffo and Enrico Bertino. Bertino: an italian distilbert model, 2023.
13. Oday Oday, Vijay Madaan, Rajaa Daami Resen, Neha Sharma, Oday Ali Hassen, and Jamal kh kh madhloom. Text categorization for information retrieval using nlp models. *Journal of Cybersecurity and Information Management*, 2025.
14. Alan Ramponi and Barbara Plank. Neural unsupervised domain adaptation in NLP—a survey. In *Proceedings of the 28th International Conference on Computational Linguistics*, pages 6838–6855, Barcelona, Spain (Online), December 2020. International Committee on Computational Linguistics.
15. Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, November 2019.
16. Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter, 2019.
17. Manan Sharma. A comparative analysis of natural language processing models: Bert and lstm in enhancing business communication. *International Journal of Innovative Science and Research Technology*, 2025.
18. Rafael Silva Barbon and Ademar Takeo Akabane. Towards transfer learning techniques—bert, distilbert, bertimbau, and distilbertimbau for automatic text classification from different languages: A case study. *Sensors*, 22(21), 2022.
19. Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers, 2020.
20. Linyi Yang, Yaoxiao Song, Xuan Ren, Chenyang Lyu, Yidong Wang, Lingqiao Liu, Jindong Wang, Jennifer Foster, and Yue Zhang. Out-of-distribution generalization in text classification: Past, present, and future, 2023.
21. Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostęp: 2026-03-26.
22. Shengkai Yuan. Empirical study on the effectiveness of distilbert fine-tuning on imdb sentiment classification outperforming cnn/lstm. *Academic Journal of Science and Technology*, 2026.
23. Yinhe Zheng, Guanyi Chen, and Minlie Huang. Out-of-domain detection for natural language understanding in dialog systems. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:1198–1209, 2020.