

Analiza cross-domain klasyfikacji ładunku emocjonalnego tekstu dla modeli SVM + TF-IDF, LSTM, BERT i DistilBERT

Selega Kamil (288780),
Sielska Małgorzata (266560),
Szczepaniak Katarzyna (261895),
Szeląg Magdalena (266857)

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji (W4N)
Kierunek: Zaufane Systemy Sztucznej Inteligencji (TAI)
Kurs: Przetwarzanie Języka Naturalnego

Zarys tematu

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (z ang. *out-of-domain text classification*, OOD). Głównym celem ewaluacji jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z zupełnie innego źródła. Spadek skuteczności w docelowym środowisku jest powszechnym problemem, dlatego celem pracy jest mierzalna, statystyczna weryfikacja utraty zdolności generalizacyjnych (metodami badającymi *accuracy* i *F1-score*) na zadaniu analizy sentymentu.

Studium literaturowe

Problem radzenia sobie przez modele z nowymi, nieznanymi podczas wczesnych etapów treningu danymi (OOD) od dawna jest jednym z większych wyzwań przetwarzania języka naturalnego. Ramy teoretyczne tego zjawiska opisują m.in. Yang i in. [16] oraz Lang i in. [9]. Zwracają oni uwagę, że pomimo świetnych wyników współczesnych sieci neuronowych w obrębie znanych danych docelowych (in-domain), skuteczność detekcji drastycznie spada przy zetknięciu z innym kontekstem wypowiedzi. Początki prób przeciwdziałania temu zjawisku sięgają klasycznej adaptacji domenowej nakierowanej jeszcze na stare klasyfikatory statystyczne, co analizowali chociażby Daumé III i Marcu [6]. Wraz z narastającym skomplikowaniem sieci, uwaga analityków przesunęła się m.in. na rozpoznawanie nowych intencji z użyciem metod nienadzorowanych (bez etykiet nowej domeny) [7] czy ugruntowanie pewności i bezpieczeństwa najnowszych zautomatyzowanych chatbotów konwersacyjnych [19].

Co ciekawe, trudności z generalizacją na dane OOD wymuszają nowe metody analiz w zróżnicowanych gałęziach NLP, m.in. psują wyniki systemów tłumaczeń [5], obniżają jakość wydobywania related entities podczas analiz tekstów

medycznych [2], a nawet generują szum decyzyjny przy segmentowaniu izolowanych tekstów języków azjatyckich przeplatanych wtrąceniami europejskimi [10]. Spadek efektywności wykracza nawet daleko poza ramy samego NLP, jest to zjawisko o dużej skali i odnosi się też do kategoryzacji obrazów wizyjnych, chociażby klasyfikacji środowiska na podsatwie rzutów satelitarnych [8].

Standardami służącymi rozwiązywaniu zagadnień poprawnej kategoryzacji zdań i wyszukiwania tekstu stały się od niedawna obok głębokich ujęć rekurencyjnych (LSTM) potężne reprezentacje opierające się natywnie na uwadze wektorowej (Transformer, m.in. popularny BERT). Szerokiej weryfikacji takich architektur podjęli się badawczo i polecają takie metody m.in. Sharma [14] oraz Oday i in. [13]. Bardzo istotną luką staje się jednak redukcja dużych rozmiarów tych procesów. Stąd naukowcy zwrócili się ku potężnym, ale optymalizowanym transfer learningiem mniejszym wersjom tych samych modeli, na czele z modelem DistilBERT. Barbon i Akabane [15] potwierdzili badawczo wysoką, często zaskakującą skuteczność lekkiego DistilBERTa nad przestarzałym oprogramowaniem we wprawnym rozładowaniu różnic domen w analizach wielojęzycznych, tak jak dowiedli to również Muffo i Bertino testując zjawisko na dużych tekstowych zasobach dla języka włoskiego [12]. Co najważniejsze dla samego zdiagnozowanego problemu w tym projekcie, Yuan [18] poparł na zbiorach IMDb skuteczność właśnie lekkiej wersji DistilBERT udowadniając przewagę celowanej detekcji Transformerowej nad metodami głębokimi (CNN i LSTM). Jednocześnie warto wspomnieć, że badając tak złożone architektury warto posługiwać się pewnymi i jasno dowodzącymi swojej pewności i poprawności (explanations) decyzjami co dowiedli szerzej na modelach OOD Chrysostomou i Aletras [3].

Plan eksperymentu

Opierając się na powyższym przeglądzie, zdecydowano się przetestować algorytm na zadaniu klasyfikacji sentymentu stosując dogłębną ewaluację krzyżową (ang. *cross-domain*). Zamiast ustalać wyłącznie jedną domenę bazową, każda z zademonstrowanych architektur będzie trenowana niezależnie dla każdego poszczególnego zbioru danych. Po wytrenowaniu modelu na danym zbiorze (źródłowym), zostanie on przetestowany na nim samym (ewaluacja *in-domain*) oraz na każdym z pozostałych (ewaluacja *out-of-domain*). Badanie rotacyjnie obejmie poniższe zbiory:

- **IMDb Dataset** (review, rating, pos/neg) - recenzje filmowe, często używane jako bazowy punkt odniesienia jakości modeli głębokich w analizie sentymentu na OOD, co opisuje Yuan [18] [11].
- **Rotten Tomatoes Dataset** - krytyczne i zróżnicowane recenzje filmowe gromadzone z portalu Rotten Tomatoes [1].
- **Amazon Reviews Dataset** - mocno ukierunkowane testy recenzji produktów różnych gabarytów [4].
- **Yelp Reviews** - naturalny slang opinii o restauracjach i zróżnicowanych małych obszarach usług lokalnych [17].

Dzięki zbudowaniu pełnej macierzy testowej (np. trening na zbiorze IMDb i testowanie na zestawach IMDb, Rotten Tomatoes, Amazon, Yelp; następnie trening na Amazon i ten sam zestaw testów itd.), badanie w pełni wykaże w praktyce, jak drastycznie zmiana rozkładu tekstu wpływa na parametry dokładności modeli wyszczególnionych w teorii przez Langa i Yanga [16,?]. W ramach protokołów testowych przyjmuje się rygorystyczny podział każdego ze środowisk danych. Aby zapewnić wiarygodność estymatorów i uniknąć przetrenowania, na etapie modelowania na warstwie źródłowej, wykorzystana zostanie k -krotna walidacja krzyżowa (ang. *k-fold cross-validation*). Zgromadzone dzięki temu uśrednione miary z ostatecznej ewaluacji pozwolą na w pełni miarodajne i statystycznie poprawne porównania.

Do weryfikacji celów postawiono na zróżnicowany stack algorytmiczny, aby porównać skuteczność pomiędzy starymi standardami klasyfikacyjnymi i innowacyjnym użyciem uwag i transformatorów [6,?]. Posłużą temu cztery stopnie trudności badanej architektury:

1. **SVM + wektoryzacja TF-IDF** - reprezentująca optymalny wczesny model z nurtu klasyfikatorów statystycznych, tworząca próg bazowego startu eksperymentu.
2. **LSTM** - stanowiący stabilniejszy, bazowy standard przetwarzania, nierzadko dający gorsze wyniki na OOD polecane w analizach do pomiaru siły różnic (zasięgnij literatury Yuana[18]).
3. **BERT** - dający obietnicę gigantycznej reprezentacji języka, nierzadko najsilniejsza wersja z możliwych.
4. **DistilBERT** - wariant pozwalający testować i dowieść czy kompresja metod obniża spadek radzenia z problem OOD po transfer learningu (teza powzięta z ujęcia Barbona [15]).

Literatura

1. Rotten tomatoes movies and critic reviews dataset. <https://www.kaggle.com/datasets/stefanoleone992/rotten-tomatoes-movies-and-critic-reviews-dataset>.
2. Ilseyar Alimova, Elena Tutubalina, and Sergey I. Nikolenko. Cross-domain limitations of neural models on biomedical relation classification. *IEEE Access*, 10:1432–1439, 2022.
3. George Chrysostomou and Nikolaos Aletras. An empirical study on explanations in out-of-domain settings, 2022.
4. Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
5. Barry Haddow and Philipp Koehn. Analysing the effect of out-of-domain data on SMT systems. In Chris Callison-Burch, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, and Lucia Specia, editors, *Proceedings of the Seventh Workshop on Statistical Machine Translation*, pages 422–432, Montréal, Canada, June 2012. Association for Computational Linguistics.
6. Hal Daumé III and Daniel Marcu. Domain adaptation for statistical classifiers. *CoRR*, abs/1109.6341, 2011.

7. Di Jin, Shuyang Gao, Seokhwan Kim, Yang Liu, and Dilek Hakkani-Tür. Towards textual out-of-domain detection without in-domain labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:1386–1395, 2022.
8. Matthew Kolodner and Jack Xiao. Evaluating deep learning approaches for out-of-domain land cover classification. 2022.
9. Hao Lang, Yinhe Zheng, Yixuan Li, Jian Sun, Fei Huang, and Yongbin Li. A survey on out-of-distribution detection in nlp, 2023.
10. Peerat Limkonchotiwat, Wannaphong Phatthiyaphaibun, Raheem Sarwar, Ekapol Chuangsuwanich, and Sarana Nutanong. Handling cross- and out-of-domain samples in thai word segmentation. In *Findings*, 2021.
11. Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostep: 2026-03-26.
12. Matteo Muffo and Enrico Bertino. Bertino: an italian distilbert model, 2023.
13. Oday Oday, Vijay Madaan, Rajaa Daami Resen, Neha Sharma, Oday Ali Hassen, and Jamal kh kh madhlom. Text categorization for information retrieval using nlp models. *Journal of Cybersecurity and Information Management*, 2025.
14. Manan Sharma. A comparative analysis of natural language processing models: Bert and lstm in enhancing business communication. *International Journal of Innovative Science and Research Technology*, 2025.
15. Rafael Silva Barbon and Ademar Takeo Akabane. Towards transfer learning techniques—bert, distilbert, bertimbau, and distilbertimbau for automatic text classification from different languages: A case study. *Sensors*, 22(21), 2022.
16. Linyi Yang, Yaoxiao Song, Xuan Ren, Chenyang Lyu, Yidong Wang, Lingqiao Liu, Jindong Wang, Jennifer Foster, and Yue Zhang. Out-of-distribution generalization in text classification: Past, present, and future, 2023.
17. Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostep: 2026-03-26.
18. Shengkai Yuan. Empirical study on the effectiveness of distilbert fine-tuning on imdb sentiment classification outperforming cnn/lstm. *Academic Journal of Science and Technology*, 2026.
19. Yinhe Zheng, Guanyi Chen, and Minlie Huang. Out-of-domain detection for natural language understanding in dialog systems. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:1198–1209, 2020.