

Temat: Out-of-Domain Text Classification

Selega Kamil,
Sielska Małgorzata,
Szczepaniak Katarzyna,
Szelaąg Magdalena

Opis Tematu

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (out-of-domain text classification). Celem jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z innego źródła.

W ramach projektu planowane jest przeprowadzenie zadania klasyfikacji sentymentu (pozytywny / negatywny). Modele zostaną wytrenowane na jednym zbiorze danych (np. recenzje filmowe z IMDb Dataset), a następnie testowane:

- na danych z tej samej domeny (in-domain),
- na danych z innej domeny (out-of-domain, np. Amazon Reviews).

Pozwoli to ocenić zdolność modeli do generalizacji oraz porównać spadek jakości klasyfikacji między środowiskiem in-domain i out-of-domain. Wyniki będą analizowane za pomocą metryk takich jak accuracy oraz F1-score, a końcowym efektem projektu będzie porównanie skuteczności modeli oraz ocena, czy bardziej zaawansowane architektury lepiej radzą sobie poza domeną treningową.

Porównywane modele

Porównane zostaną modele o różnym poziomie złożoności:

- Regresja logistyczna + TF-IDF
- LSTM

- BERT
- DistilBERT

Proponowane zbiory danych

- **IMDb Dataset** (review, rating, pos/neg) - recenzje filmów [2].
- **Amazon Reviews Dataset** (review title, review text, rating) - recenzje produktów [1].
- **Yelp Reviews** (text, stars) - recenzje restauracji i usług [3].

Literatura

- [1] Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
- [2] Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostęp: 2026-03-26.
- [3] Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostęp: 2026-03-26.