

Analiza cross-domain klasyfikacji ładunku emocjonalnego tekstu dla modeli SVM + TF-IDF, LSTM, BERT i DistilBERT

Selega Kamil (288780),
Sielska Małgorzata (266560),
Szczepaniak Katarzyna (261895),
Szeląg Magdalena (266857)

No Institute Given

Zarys tematu

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (z ang. *out-of-domain text classification*, OOD). Głównym celem ewaluacji jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z zupełnie innego źródła. Spadek skuteczności w docelowym środowisku jest powszechnym problemem, dlatego celem pracy jest mierzalna, statystyczna weryfikacja utraty zdolności generalizacyjnych (metodami badającymi *accuracy* i *F1-score*) na zadaniu analizy sentymentu.

Studium literaturowe

Problem radzenia sobie przez modele z nowymi, nieznanymi podczas wczesnych etapów treningu danymi (OOD) od dawna jest jednym z większych wyzwań przetwarzania języka naturalnego. Ramy teoretyczne tego zjawiska opisują m.in. Yang i in. [16] oraz Lang i in. [9]. Zwracają oni uwagę, że pomimo świetnych wyników współczesnych sieci neuronowych w obrębie znanych danych docelowych (in-domain), skuteczność detekcji drastycznie spada przy zetknięciu z innym kontekstem wypowiedzi. Początki prób przeciwdziałania temu zjawisku sięgają klasycznej adaptacji domenowej nakierowanej jeszcze na stare klasyfikatory statystyczne, co analizowali chociażby Daumé III i Marcu [6]. Wraz z narastającym skomplikowaniem sieci, uwaga analityków przesunęła się m.in. na rozpoznawanie nowych intencji z użyciem metod nienadzorowanych (bez etykiet nowej domeny) [7] czy ugruntowanie pewności i bezpieczeństwa najnowszych zautomatyzowanych chatbotów konwersacyjnych [19].

Co ciekawe, trudności z generalizacją na dane OOD wymuszają nowe metody analiz w zróżnicowanych gałęziach NLP, m.in. psują wyniki systemów tłumaczeń [5], obniżają jakość wydobywania related entities podczas analiz tekstów medycznych [2], a nawet generują szum decyzyjny przy segmentowaniu izolowanych tekstów języków azjatyckich przeplatanych wtrąceniami europejskimi [10].

Spadek efektywności wykracza nawet daleko poza ramy samego NLP, jest to zjawisko o dużej skali i odnosi się też do kategoryzacji obrazów wizyjnych, chociażby klasyfikacji środowiska na podsatwie rzutów satelitarnych [8].

Standardami służącymi rozwiązywaniu zagadnień poprawnej kategoryzacji zdań i wyszukiwania tekstu stały się od niedawna obok głębokich ujęć rekurencyjnych (LSTM) potężne reprezentacje opierające się natywnie na uwadze wektorowej (Transformer, m.in. popularny BERT). Szerokiej weryfikacji takich architektur podjęli się badawczo i polecają takie metody m.in. Sharma [14] oraz Oday i in. [13]. Bardzo istotną luką staje się jednak redukcja dużych rozmiarów tych procesów. Stąd naukowcy zwrócili się ku potężnym, ale optymalizowanym transfer learningiem mniejszym wersjom tych samych modeli, na czele z modelem DistilBERT. Barbon i Akabane [15] potwierdzili badawczo wysoką, często zaskakującą skuteczność lekkiego DistilBERTa nad przestarzałym oprogramowaniem we wprawnym rozładowaniu różnic domen w analizach wielojęzycznych, tak jak dowiedli to również Muffo i Bertino testując zjawisko na dużych tekstowych zasobach dla języka włoskiego [12]. Co najważniejsze dla samego zdiagnozowanego problemu w tym projekcie, Yuan [18] poparł na zbiorach IMDb skuteczność właśnie lekkiej wersji DistilBERT udowadniając przewagę celowanej detekcji Transformerowej nad metodami głębokimi (CNN i LSTM). Jednocześnie warto wspomnieć, że badając tak złożone architektury warto posługiwać się pewnymi i jasno dowodzącymi swojej pewności i poprawności (explanations) decyzjami co dowiedli szerzej na modelach OOD Chrysostomou i Aletras [3].

Plan eksperymentu

Opierając się na powyższym przeglądzie, zdecydowano się przetestować algorytmy na zadaniu klasyfikacji sentymentu stosując dogłębną ewaluację krzyżową (ang. *cross-domain*). Zamiast ustalać wyłącznie jedną domenę bazową, każda z zademonstrowanych architektur będzie trenowana niezależnie dla każdego poszczególnego zbioru danych. Po wytrenowaniu modelu na danym zbiorze (źródłowym), zostanie on przetestowany na nim samym (ewaluacja *in-domain*) oraz na każdym z pozostałych (ewaluacja *out-of-domain*). Badanie rotacyjnie obejmie poniższe zbiory:

- **IMDb Dataset** (review, rating, pos/neg) - recenzje filmowe, często używane jako bazowy punkt odniesienia jakości modeli głębokich w analizie sentymentu na OOD, co opisuje Yuan [18] [11].
- **Rotten Tomatoes Dataset** - krytyczne i różnicowane recenzje filmowe gromadzone z portalu Rotten Tomatoes [1].
- **Amazon Reviews Dataset** - mocno ukierunkowane testy recenzji produktów różnych gabarytów [4].
- **Yelp Reviews** - naturalny slang opinii o restauracjach i różnicowanych małych obszarach usług lokalnych [17].

Dzięki zbudowaniu pełnej macierzy testowej (np. trening na zbiorze IMDb i testowanie na zestawach IMDb, Rotten Tomatoes, Amazon, Yelp; następnie tre-

ning na Amazon i ten sam zestaw testów itd.), badanie w pełni wykaże w praktyce, jak drastycznie zmiana rozkładu tekstu wpływa na parametry dokładności modeli wyszczególnionych w teorii przez Langa i Yanga [16,?]. W ramach protokołów testowych przyjmuje się rygorystyczny podział każdego ze środowisk danych. Aby zapewnić wiarygodność estymatorów i uniknąć przetrenowania, na etapie modelowania na warstwie źródłowej, wykorzystana zostanie k -krotna walidacja krzyżowa (ang. *k-fold cross-validation*). Zgromadzone dzięki temu uśrednione miary z ostatecznej ewaluacji pozwolą na w pełni miarodajne i statystycznie poprawne porównania.

Do weryfikacji celów postawiono na zróżnicowany stack algorytmiczny, aby porównać skuteczność pomiędzy starymi standardami klasyfikacyjnymi i innowacyjnym użyciem uwag i transformatorów [6,?]. Posłużą temu cztery stopnie trudności badanej architektury:

1. **SVM + wektoryzacja TF-IDF** - reprezentująca optymalny wczesny model z nurtu klasyfikatorów statystycznych, tworząca próg bazowego startu eksperymentu.
2. **LSTM** - stanowiący stabilniejszy, bazowy standard przetwarzania, nierzadko dający gorsze wyniki na OOD polecane w analizach do pomiaru siły różnic (zasięgnij literatury Yuana[18]).
3. **BERT** - dający obietnicę gigantycznej reprezentacji języka, nierzadko najsilniejsza wersja z możliwych.
4. **DistilBERT** - wariant pozwalający testować i dowieść czy kompresja metod obniża spadek radzenia z problem OOD po transfer learningu (teza powzięta z ujęcia Barbona [15]).

Literatura

1. Rotten tomatoes movies and critic reviews dataset. <https://www.kaggle.com/datasets/stefanoleone992/rotten-tomatoes-movies-and-critic-reviews-dataset>.
2. Ilseyar Alimova, Elena Tutubalina, and Sergey I. Nikolenko. Cross-domain limitations of neural models on biomedical relation classification. *IEEE Access*, 10:1432–1439, 2022.
3. George Chrysostomou and Nikolaos Aletras. An empirical study on explanations in out-of-domain settings, 2022.
4. Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
5. Barry Haddow and Philipp Koehn. Analysing the effect of out-of-domain data on SMT systems. In Chris Callison-Burch, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, and Lucia Specia, editors, *Proceedings of the Seventh Workshop on Statistical Machine Translation*, pages 422–432, Montréal, Canada, June 2012. Association for Computational Linguistics.
6. Hal Daumé III and Daniel Marcu. Domain adaptation for statistical classifiers. *CoRR*, abs/1109.6341, 2011.
7. Di Jin, Shuyang Gao, Seokhwan Kim, Yang Liu, and Dilek Hakkani-Tür. Towards textual out-of-domain detection without in-domain labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:1386–1395, 2022.

8. Matthew Kolodner and Jack Xiao. Evaluating deep learning approaches for out-of-domain land cover classification. 2022.
9. Hao Lang, Yinhe Zheng, Yixuan Li, Jian Sun, Fei Huang, and Yongbin Li. A survey on out-of-distribution detection in nlp, 2023.
10. Peerat Limkonchotiwat, Wannaphong Phatthiyaphaibun, Raheem Sarwar, Ekapol Chuangsuwanich, and Sarana Nutanong. Handling cross- and out-of-domain samples in thai word segmentation. In *Findings*, 2021.
11. Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostep: 2026-03-26.
12. Matteo Muffo and Enrico Bertino. Bertino: an italian distilbert model, 2023.
13. Oday Oday, Vijay Madaan, Rajaa Daami Resen, Neha Sharma, Oday Ali Hassen, and Jamal kh kh madhlloom. Text categorization for information retrieval using nlp models. *Journal of Cybersecurity and Information Management*, 2025.
14. Manan Sharma. A comparative analysis of natural language processing models: Bert and lstm in enhancing business communication. *International Journal of Innovative Science and Research Technology*, 2025.
15. Rafael Silva Barbon and Ademar Takeo Akabane. Towards transfer learning techniques—bert, distilbert, bertimbau, and distilbertimbau for automatic text classification from different languages: A case study. *Sensors*, 22(21), 2022.
16. Linyi Yang, Yaoxiao Song, Xuan Ren, Chenyang Lyu, Yidong Wang, Lingqiao Liu, Jindong Wang, Jennifer Foster, and Yue Zhang. Out-of-distribution generalization in text classification: Past, present, and future, 2023.
17. Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostep: 2026-03-26.
18. Shengkai Yuan. Empirical study on the effectiveness of distilbert fine-tuning on imdb sentiment classification outperforming cnn/lstm. *Academic Journal of Science and Technology*, 2026.
19. Yinhe Zheng, Guanyi Chen, and Minlie Huang. Out-of-domain detection for natural language understanding in dialog systems. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:1198–1209, 2020.