

Temat: Out-of-Domain Text Classification

Selega Kamil (288780),
Sielska Małgorzata (266560),
Szczepaniak Katarzyna (261895),
Szeląg Magdalena (266857)

Opis Tematu

Projekt dotyczy analizy odporności modeli klasyfikacji tekstu na zmianę domeny danych (out-of-domain text classification). Celem jest sprawdzenie, w jakim stopniu modele uczone na jednym typie tekstów potrafią poprawnie klasyfikować dane pochodzące z innego źródła.

W ramach projektu planowane jest przeprowadzenie zadania klasyfikacji sentymentu (pozytywny / negatywny). Modele zostaną wytrenowane na jednym zbiorze danych (np. recenzje filmowe z IMDB Dataset), a następnie testowane:

- na danych z tej samej domeny (in-domain),
- na danych z innej domeny (out-of-domain, np. Amazon Reviews).

Pozwoli to ocenić zdolność modeli do generalizacji oraz porównać spadek jakości klasyfikacji między środowiskiem in-domain i out-of-domain. Wyniki będą analizowane za pomocą metryk takich jak accuracy oraz F1-score, a końcowym efektem projektu będzie porównanie skuteczności modeli oraz ocena, czy bardziej zaawansowane architektury lepiej radzą sobie poza domeną treningową.

Studium literaturowe

Problem radzenia sobie przez modele z danymi pochodzącymi spoza domeny treningowej (tzw. Out-of-Domain, OOD) od dawna jest ważnym tematem w przetwarzaniu języka naturalnego. Yang i in. [15] oraz Lang i in. [8] opisują rozwój i wyzwania w tej dziedzinie. Zwracają uwagę, że choć dzisiejsze modele

świetnie działają na danych podobnych do tych z treningu (in-domain), to ich skuteczność drastycznie spada, gdy stykają się z nowym typem tekstów.

Początki tych badań sięgają klasycznej adaptacji domenowej, którą początkowo rozwijano dla prostszych klasyfikatorów statystycznych, co pokazali Daumé III i Marcu [5]. Dziś badacze skupiają się na trudniejszych kwestiach, takich jak wykrywanie nowych, nieznanych danych bez korzystania z gotowych etykiet, co analizują Jin i in. [6]. Z kolei Zheng i in. [18] sprawdzali, jak dobrze systemy konwersacyjne (chatboty) radzą sobie z nowymi intencjami użytkowników na danych, których wcześniej nie widziały.

Spadek skuteczności na danych testowych z innych domen dotyka bardzo różnych zadań tekstowych. Zaobserwowano to na przykład przy projektowaniu systemów tłumaczenia maszynowego [4], przy szukaniu relacji i powiązań w skomplikowanych tekstach medycznych [1], a nawet przy dzieleniu na słowa tajskiego tekstu, w którym znajdują się obcojęzyczne wtrącenia [9]. Co ciekawe, dokładnie te same problemy z generalizacją na nowe typy danych pojawiają się zupełnie poza NLP – chociażby przy klasyfikacji terenu na zdjęciach satelitarnych [7].

Żeby sprostać tym wyzwaniom, w ostatnich latach szeroko stosuje się potężne algorytmy oparte na modelu Transformer (jak np. BERT) oraz klasyczne warianty sieci rekurencyjnych. Sharma [13] porównał takie modele i potwierdził ich świetną skuteczność w zadaniach kategoryzacji tekstu. Użyteczność podobnych klasyfikatorów w systemach pomagających wyszukiwać informacje badał z kolei Oday i in. [12]. Bardzo ważnym podejściem – szczególnie gdy zależy nam na mniejszym zużyciu zasobów – są zoptymalizowane modele z rodziny BERT, jak DistilBERT. Barbon i Akabane [14] na przykładzie angielskich i portugalskich tekstów pokazali, że mimo mniejszego rozmiaru sieci, radzi ona sobie znakomicie z danymi OOD. Słuszność pójścia w mniejsze modele potwierdzają także Muffo i Bertino [11] na zbiorach dla języka włoskiego. Wracając do naszego głównego zadania – badanie przeprowadzone przez Yuana [17] dokładnie z użyciem recenzji filmowych (zbiór IMDb) dowiodło, że odpowiednio dostrojony model DistilBERT wypada w klasyfikacji sentymentu znacznie lepiej niż łączone architektury CNN i LSTM. Należy też pamiętać, że na nowych rodzajach danych modele mogą zachowywać się w sposób niezrozumiały – wpływ zmiany domeny na trafność tłumaczenia i analiz przez algorytmy badali Chrysostomou i Aletras [2].

Porównywane modele

Porównane zostaną modele o różnym poziomie złożoności:

- Regresja logistyczna + TF-IDF

- LSTM
- BERT
- DistilBERT

Proponowane zbiory danych

- **IMDb Dataset** (review, rating, pos/neg) - recenzje filmów [10].
- **Amazon Reviews Dataset** (review title, review text, rating) - recenzje produktów [3].
- **Yelp Reviews** (text, stars) - recenzje restauracji i usług [16].

Literatura

- [1] Ilseyar Alimova, Elena Tutubalina, and Sergey I. Nikolenko. Cross-domain limitations of neural models on biomedical relation classification. *IEEE Access*, 10:1432–1439, 2022.
- [2] George Chrysostomou and Nikolaos Aletras. An empirical study on explanations in out-of-domain settings, 2022.
- [3] Dongrelaxman. Amazon reviews dataset. <https://www.kaggle.com/datasets/dongrelaxman/amazon-reviews-dataset>. Dostęp: 2026-03-26.
- [4] Barry Haddow and Philipp Koehn. Analysing the effect of out-of-domain data on SMT systems. In Chris Callison-Burch, Philipp Koehn, Christof Monz, Matt Post, Radu Soricut, and Lucia Specia, editors, *Proceedings of the Seventh Workshop on Statistical Machine Translation*, pages 422–432, Montréal, Canada, June 2012. Association for Computational Linguistics.
- [5] Hal Daumé III and Daniel Marcu. Domain adaptation for statistical classifiers. *CoRR*, abs/1109.6341, 2011.
- [6] Di Jin, Shuyang Gao, Seokhwan Kim, Yang Liu, and Dilek Hakkani-Tür. Towards textual out-of-domain detection without in-domain labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:1386–1395, 2022.

- [7] Matthew Kolodner and Jack Xiao. Evaluating deep learning approaches for out-of-domain land cover classification. 2022.
- [8] Hao Lang, Yinhe Zheng, Yixuan Li, Jian Sun, Fei Huang, and Yongbin Li. A survey on out-of-distribution detection in nlp, 2023.
- [9] Peerat Limkonchotiwat, Wannaphong Phatthiyaphaibun, Raheem Sarwar, Ekapol Chuangsuwanich, and Sarana Nutanong. Handling cross-and out-of-domain samples in thai word segmentation. In *Findings*, 2021.
- [10] Andrew L. Maas et al. Imdb dataset of 50k movie reviews. <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>. Dostęp: 2026-03-26.
- [11] Matteo Muffo and Enrico Bertino. Bertino: an italian distilbert model, 2023.
- [12] Oday Oday, Vijay Madaan, Rajaa Daami Resen, Neha Sharma, Oday Ali Hassen, and Jamal kh kh madhlloom. Text categorization for information retrieval using nlp models. *Journal of Cybersecurity and Information Management*, 2025.
- [13] Manan Sharma. A comparative analysis of natural language processing models: Bert and lstm in enhancing business communication. *International Journal of Innovative Science and Research Technology*, 2025.
- [14] Rafael Silva Barbon and Ademar Takeo Akabane. Towards transfer learning techniques—bert, distilbert, bertimbau, and distilbertimbau for automatic text classification from different languages: A case study. *Sensors*, 22(21), 2022.
- [15] Linyi Yang, Yaoxiao Song, Xuan Ren, Chenyang Lyu, Yidong Wang, Lingqiao Liu, Jindong Wang, Jennifer Foster, and Yue Zhang. Out-of-distribution generalization in text classification: Past, present, and future, 2023.
- [16] Yelp. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/> oraz <https://www.kaggle.com/datasets/omkarsabnis/yelp-reviews-dataset>. Dostęp: 2026-03-26.
- [17] Shengkai Yuan. Empirical study on the effectiveness of distilbert fine-tuning on imdb sentiment classification outperforming cnn/lstm. *Academic Journal of Science and Technology*, 2026.

- [18] Yinhe Zheng, Guanyi Chen, and Minlie Huang. Out-of-domain detection for natural language understanding in dialog systems. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 28:1198–1209, 2020.